

特集論文

単語極性反転モデルによる評価文分類

Learning to Shift the Polarity of Words for Sentiment Classification

池田 大介^{*1}
Daisuke Ikeda東京工業大学
Tokyo Institute of Technology
ikedai@lr.pi.titech.ac.jp, <http://www.lr.pi.titech.ac.jp/~ikedai/>高村 大也
Hiroya Takamura(同 上)
takamura@pi.titech.ac.jp, <http://www.lr.pi.titech.ac.jp/~takamura/>奥村 学
Manabu Okumura(同 上)
oku@pi.titech.ac.jp, <http://www.lr.pi.titech.ac.jp/~oku/>**keywords:** sentiment analysis, sentence classification, structure output learning

Summary

We propose a machine learning based method of sentiment classification of sentences using word-level polarity. The polarities of words in a sentence are not always the same as that of the sentence, because there can be polarity-shifters such as negation expressions. The proposed method models the polarity-shifters. Our model can be trained in two different ways: word-wise and sentence-wise learning. In sentence-wise learning, the model can be trained so that the prediction of sentence polarities should be accurate. The model can also combined with features used in previous work such as bag-of-words and n-grams. We empirically show that our method improves the performance of sentiment classification of sentences especially when we have only small amount of training data.

1. は じ め に

Web の普及に伴い, 個人が手軽に情報を発信できるようになった. blog や掲示板などがその好例である. 個人の発する情報には, 事物に対する評価や感情が記述されることが多い. 近年こういった情報に対する関心が高まっており, 評価情報分析に関する研究が数多くなされている [乾 06].

中でも, 文書や文をその著者の感情極性によってポジティブ (望ましい), ネガティブ (望ましくない) の二つに分類するというタスクは盛んに研究されている [乾 06]. このタスクは, Web 中の文書や文からある物に対する評判を検索する, といったアプリケーションに応用することが可能で, 重要かつ実用的なタスクである.

他方, 文書や文の他に, 単語に対する感情極性についての研究も行われている. 例えば, “美味しい” という語はポジティブな極性を持っていると考えられ, “苦い” はネガティブな極性を持つ語であるといえる. このような単語に対する感情極性を自動的に付与し, 単語の極性辞書を構築する手法が提案されている [Hatzivassiloglou 97, 小林 01, Turney 03, Kamps 04, Hu 04, 高村 06]. 単語の感情極性は, 評価情報を考える上での基礎であり, 様々な問題への利用が考えられる. データを辞書として用意す

ることが可能であり, 他のタスクへの利用が容易であるというメリットもある.

評価文の分類というタスクに於いても, 単語の極性は有用な情報であると考えられる. しかし, どのように単語の極性を利用すれば評価文分類の精度を向上させられるかは明らかになっていない. そこで, 本稿では単語に付与された極性を文レベルの分類に利用する手法を提案する. 単純には, 多数決を用いることで, 単語の感情極性を利用した評価文の分類は可能である. しかし, 実際には単語の極性とそれを含む評価文の極性とは必ずしも一致しない. これは, 逆接や否定など, 様々な文脈により単語の極性が反転することがあるためである. こういった現象は, 単純な多数決では致命的な誤りの原因となる. 逆に言えば, こういった極性の反転を捉えることは, 評価文分類に単語の極性を利用する上で重要な事象である. 反転を引き起こす表現を人手で網羅するのは, 表現の多様性を考えると困難である. そこで, 我々はこの事象を捉える統計学習ベースの単語極性反転モデルを提案する. 反転を捉えることで, 単純な多数決であっても上記のようなエラーを回避する事ができる. さらに, このモデルは単語単位ではなく, 文単位の学習が可能である. そうすることで, 単語極性反転モデルを用いて直接評価文分類が可能となり, その精度を高める事ができる. また, このモデルは従来の機械学習による評価文分類モデルと自然な形で結合可能であるので, 文中の単語の極性を利用

^{†1} 現在はグーグルジャパンに勤務.

しつつ、これまで提案されてきた様々な情報を考慮したモデルが構築可能である。

本稿では、提案手法の有効性を確認するため、英語レビュー文に対し評価文分類の評価実験を行う。

本稿は以下のように構成される。まず2節で、関連研究について述べる。その後3節で、既存の単語極性の利用法について論じ、本研究の動機と背景を明らかにする。4節で提案手法である単語極性反転モデルについて述べ、その学習法と評価文分類法について説明する。評価実験の詳細とその考察について5節で述べ、6節で結論と今後の課題を挙げる。

2. 関連研究

先にも述べた通り、評価文分類や評価文書分類に関する研究は近年広く行われている[乾 06]。中でも、サポートベクターマシン(SVM)を始めとする教師有りの機械学習による手法は高い精度を残している[Pang 02][Matsumoto 05][Gamon 04][工藤 04][Mullen 04]。この手法は様々な素性を柔軟に取り入れることができるという点で優れており、依存構造木や語の系列など様々な情報を用いる手法が提案されている[Matsumoto 05][工藤 04]。本研究はこういった評価文そのものの持つ情報ではなく、文に含まれる単語の持つ極性という異なる階層の情報を取り込む手法を提案する。また、先行研究で提案されたような情報を自然に取り込むことも可能である。

本研究は、文と単語という自然言語における階層に着目し、ある階層の情報を別の階層の解析に利用しようという試みである。先行研究においても、こういった階層に着目した研究はいくつかなされている。Maoら[Mao 06]や貞光ら[貞光 07]は、文書中の各文における感情極性の推移を捉える手法を提案しており、この手法を用いることで評価文書分類そのものの精度を高めることができることを報告している。ある対象の持つ感情極性と、そこに含まれる要素の感情極性は必ずしも一致しないという点に着目しており、本研究で考慮する感情極性の反転もこの一種であると言える。

他にも、階層に着目した評価情報に関する研究としてPangら[Pang 04]や、McDonaldら[McDonald 07]による手法が挙げられる。Pangらは、主観的な文こそが文書の感情極性の推定には有効という考えの下、各文の主観性を推定した後に評価文書分類を行うという手法を提案している[Pang 04]。あらかじめ客観的な文を削除することで、評価文書分類の結果が良くなると報告している。McDonaldらは、文単位での分類問題と文書単位での分類問題を同時に解くモデルを提案している[McDonald 07]。彼らは文単位で主観性を、文書単位では感情極性を、同時に推定することで、通常の評価文書分類よりも高い精度が得られることを示した。また、文書-文間の二階層だけでなく、文書-段落-文といった3階層以上の構造

に対しても適用可能であると論じている。

これらの研究の多くは、文書に対する感情極性と同時に、そこに含まれる文の主観性といった、考慮する全ての階層に対する教師データを必要としている。我々の研究も、これらの先行研究同様、階層に着目した評価情報分析であるが、単語の極性辞書があれば教師データとしては評価文とその感情極性のみしか必要としないという点で大きく異なる。

3. 単語極性の既存の利用法

単語の感情極性を利用した評価文分類手法のうち、もっとも単純な手法は多数決である。すなわち、分類対象の文に出現するポジティブ極性の付与された単語とネガティブ極性の付与された単語の数を数え、多く出現していた極性を文全体の極性と判定する、という手法である^{*1}。

この手法はいくつかの致命的な欠点を持つ。一つ目は、文全体の極性とその文中に出現する単語の極性は必ずしも一致しないにも関わらず、その現象を一切考慮できないという点である。以下に具体的な例を挙げる。

照明が 暗い など一部 不満 もあるけど、全体としては 良かった。

なお、下線の引かれた単語はネガティブな単語、二重下線の引かれた単語はポジティブな単語である。この文は局所的にはネガティブな表現も含まれるが、全体としてはポジティブ極性を持つ文であると言える。しかし、この文を上記の多数決によって極性を推定すると、ネガティブ極性を持つ単語が2語あることから、全体をネガティブと判定してしまう。こういった事例は頻繁に存在し、多数決による評価文分類の精度を大きく下げる原因となる。これは、単純な多数決では“けど”のような逆接表現や否定表現を考慮できないことに起因する。つまり、評価文分類に単語極性辞書を利用する上で、逆接や否定と言った単語の極性反転を捉えることが重要であると言える。

また、既存の手法と組み合わせることが難しいという問題も存在する。多数決はあくまで単語の数を数えるだけであり、従来用いられてきたBag-of-Wordsや木構造といった情報を取り込むことができない。本研究では、単語の感情極性を利用した評価文分類を提案するが、単語の感情極性だけから評価文の分類を行うのでは限界がある。提案手法である単語極性反転モデルを利用した評価文分類手法では、既存の評価文分類モデルとの結合も可能である。

^{*1} 5節では、この手法を Simple-Voting と呼び、比較実験に用いる。

4. 単語極性反転モデル

前節で述べた通り、文中に出現する単語は、様々な理由によりその極性が反転しており、文全体の極性と単語のそれとが一致するとは限らない。逆に言えば、文全体の極性と異なる極性を持つ単語が文中に出現する場合、その単語は文脈等によって極性が反転していると考えられる。単純な多数決による手法であっても、このような反転を捉えることにより、よりよい精度が得られると思われる。

本研究では、この現象を捉えるため単語極性反転モデルを提案する。このモデルは、感情極性を持つ単語の周辺の否定表現や逆接と言った文脈を利用し、その単語の極性が反転しているか否かを判定する二値分類モデルである。

単語極性反転モデルは、文 S 中の各極性付きの単語 x に対しスコア関数 $s_{shift}(x, S)$ を与える。この関数は、その単語の極性が文中で反転していれば $s_{shift}(x, S) > 0$ 、そうでなければ $s_{shift}(x, S) \leq 0$ を返す。なお、モデルのパラメータを w とし、スコア関数 $s_{shift}(x, S)$ は内積と素性関数 ϕ を用いて以下のように定義する：

$$s_{shift}(x, S) = w \cdot \phi(x, S). \quad (1)$$

素性関数 ϕ として、文 S において単語 x の前後に出現する単語などを用いることにより、否定表現や逆接表現による極性反転をとらえる。

このモデルは一般的な線形識別モデルであり、様々なパラメータ推定アルゴリズムが知られている。こういった場合、各単語を個々の事例として学習する方法が一般的である。しかし、極性反転を示唆する情報が文脈に出現しないこともあり、そのような事例は単語単位の学習においてノイズになってしまう。そこで 4.2 節で説明するように、各極性付き単語でなくそれらを含む文全体を一つの事例と考え、文内の極性付き単語のスコアの合計の正負が文の極性と一致するように学習を行うことで、このような問題に対処する。また、このモデルによって単語ごとの極性が文脈によって反転しているか否かを捉えることは可能だが、それだけでは評価文分類を行うことはできない。本節の残りでは本モデルの学習法と、評価文分類への利用法について述べる。

4.1 単語単位学習

単純には、各単語を事例とすることで単語極性反転モデルの学習は可能である。訓練事例は、極性の付与された評価文コーパスより感情極性の付与された単語を抜き出し、文全体の感情極性と単語の極性が一致しているか否かを見ることで生成できる。なお、感情極性の付与された単語とは、単語感情極性辞書のエントリであり、その感情極性も辞書に準ずる。先に挙げた例では、ポジティブな感情極性で書かれた文中に、“暗い”、“不満”とい

たネガティブ極性を持つ単語と“良い”というポジティブ極性を持つ単語が出現していた。単語極性反転モデルの訓練事例としては、文全体の極性とそれが一致しない“暗い”、“不満”を反転の正例として、極性の一致する“良い”を負例として学習する。

また、こうして学習されたモデルを評価文分類に利用するには、先にも述べた多数決による手法を用いればよい。モデルを分類対象である文に含まれる極性付きの単語に適用し、その結果を用いて多数決を行う。ポジティブ極性を持つ単語が反転していた場合には、その単語はネガティブ極性を持つ単語として扱えばよい。単語の極性をそのまま用いた多数決では良い結果が得られないということは先述した通りだが、各単語の極性の反転を考慮することで精度の向上が期待できる。

なお、多数決をする際には、ポジティブ極性を持つ単語とネガティブ極性を持つ単語の数を数えるだけでなく、単語極性反転モデルの出力するスコアによる重み付き多数決を用いる。これは、モデルの出力するスコアが反転に対するある種の確信度として働くことを期待するためである。

この手法を定式化すると以下のように書ける。ここで、 N, P は辞書にそれぞれネガティブ、ポジティブとして登録されている単語の集合とする。すなわち $x \in N$ であれば、 x はネガティブ極性を持つ単語である。また、単語 x が文 S に含まれる事を $x \in S$ と表すことにする。まず、文 S に対する 2 つのスコア $score_p(S)$ と $score_n(S)$ を定義する。 $score_p(S)$ は重み付き多数決における“文 S がポジティブ極性を持つことを支持する票数”に、 $score_n(S)$ は“ネガティブ極性を持つことを支持する票数”にそれぞれ相当する。つまり、 $score_p(S) > score_n(S)$ であれば文 S はポジティブな極性を、そうでなければネガティブな極性を持つと判定する。 $score_p(S)$ は、文 S 中に出現するポジティブ極性を持つ単語 $x \in S \cap P$ が“反転しない”スコア $-s_{shift}(x, S)$ に、同じくネガティブ極性を持つ単語 $x \in S \cap N$ が“反転する”スコア $s_{shift}(x, S)$ を加えた物である。数式で表すと以下の通りである：

$$score_p(S) = \sum_{x \in P \cap S} -s_{shift}(x, S) + \sum_{x \in N \cap S} s_{shift}(x, S), \quad (2)$$

$$score_n(S) = \sum_{x \in P \cap S} s_{shift}(x, S) + \sum_{x \in N \cap S} -s_{shift}(x, S). \quad (3)$$

これらの間には、以下の関係が成り立つ：

$$score_n(S) = -score_p(S). \quad (4)$$

よって、 $score_p(S) > score_n(S)$ と $score_p(S) > 0$ は同値であるので、 $score_p(S) > 0$ であれば、ポジティブ、そうでなければネガティブと判定することができる。これ以降、本稿では $score_p(S)$ のみを用いて説明をする。

4.2 文単位学習

式 (2) は、単語極性反転モデルの定義を用いて以下のように変形できる:

$$\begin{aligned} score_p(S) &= \sum_{x \in S} s_{shift}(x, S) I(x) \\ &= \sum_{x \in S} \mathbf{w} \cdot \phi(x, S) I(x) \\ &= \mathbf{w} \cdot \left\{ \sum_{x \in S} \phi(x, S) I(x) \right\}. \end{aligned} \quad (5)$$

ただし、 $I(x)$ は以下で定義される関数である:

$$I(x) = \begin{cases} +1 & \text{if } x \in N, \\ -1 & \text{if } x \in P, \\ 0 & \text{それ以外.} \end{cases} \quad (6)$$

この $score_p(S)$ は再び \mathbf{w} をパラメータとする線形識別モデルになっており、 $\sum_{x \in S} \phi(x, S) I(x)$ を一つの事例とみなして直接パラメータを推定することが可能である。

このモデルはいわば多数決された結果を直接出力するモデルであり、単語の極性の反転を元に評価文を分類するモデルとなっている。学習時には評価文とその極性を教師データとして直接用いることができる。すなわち、コーパス中のポジティブ極性を持つ文を正例、ネガティブ極性を持つ文を負例として学習する。先の例で言えば、文そのものを一つの正例として扱う。学習されるのはあくまで単語極性反転モデルのパラメータ \mathbf{w} であることから、これは単語極性反転モデルを単語単位ではなく、文単位のモデルとして捉えて学習する手法であると言える。この手法では、各単語について反転を学習するのではなく、文全体での結果が最適になるように学習を行う。この結果、反転しているか否かの判定が難しい単語に対してはスコアの絶対値を小さくし、同じ文に出現する判定の容易な単語から文全体の極性を決定するという、柔軟な学習が可能である。

単語単位学習では、評価文中に出現する全ての極性付きの単語から反転したか否かを学習する。つまり、全ての単語が評価文全体の極性と何らかの関係があり、文全体と異なる極性を持つ単語が出現する際には必ず周囲にその要因が存在する事を仮定している。これは明らかに強引な仮定である。実際には評価文の極性に影響を与えない単語もしばしば存在する。単語単位に学習を行うと、文の極性に影響しないような単語であっても教師データとして扱われ、それをラベル通りに分離するような分離面が引かれてしまう。これは反転を捉えるという本来の目的にそぐわない。文単位学習を用いて柔軟な学習を行うことで、この強引な仮定をある程度緩和することができる。評価文の極性に影響を与えないような単語に対しては強く学習せず、スコアの絶対値を低く抑えることで目的通りのモデルを学習することができる。

4.3 文単位学習と既存のモデルとの結合

これまでに述べた評価文分類法は、共に評価文中の極性付きの単語のみから文全体での極性を推定するものである。文全体の極性は、そこに含まれる単語の極性に大きく依存すると思われるため、これらの手法でも文の感情極性の推定は可能である。

他方、これまでの評価文分類や評価文書分類に関する研究では、文中の単語集合である Bag-of-Words を用いた手法 [Pang 02] や、係り受け解析による文の構造の情報をを用いる手法 [Matsumoto 05][工藤 04] が提案されてきた。本研究の提案手法である単語極性反転モデルによる評価文分類は、これらの先行研究とは用いる情報や分類に対する観点が異なる。そのため提案手法と従来法を組み合わせる事でよりよい結果が期待できる。

従来の評価文分類や評価文書分類では、用いる情報は様々であるが、SVM をはじめとする識別モデルによる分類が広く用いられてきた [Pang 02]。この手法は、一般に以下の関数による分類であると考えることができる:

$$score'_p(X) = \mathbf{w}' \cdot \phi'(X). \quad (7)$$

ここで、 X は分類対象、つまり評価文書分類では文書、評価文分類では文に相当する。 $score'_p(X) > 0$ ならば X は目的クラス (ここではポジティブ) に分類される。 $\phi'(X)$ は素性関数であり、Bag-of-Words を用いた手法であれば、文や文書 X を単語ベクトルへ射影する。依存構造木などの木構造を利用する場合、木カーネルを用いる手法 [工藤 04] が知られているが、この場合であっても $\phi'(X)$ は X に含まれる全ての部分木を列挙したベクトルを出力する関数と考えることができる。ここで、文単位学習法によるスコア関数 $score_p(S)$ と、従来法によるスコア関数 $score'_p(S)$ の線形和を、新たなモデルのスコア関数 $score_{comb}(S)$ として定義する。すると以下のように書ける:

$$\begin{aligned} score_{comb}(S) &= \lambda score_p(S) + (1 - \lambda) score'_p(S) \\ &= \lambda \sum_{x \in S} \mathbf{w} \cdot \phi(x, S) I(x) + (1 - \lambda) \mathbf{w}' \cdot \phi'(S) \\ &= \mathbf{w}_{comb} \cdot \left\langle \lambda \sum_{x \in S} \phi(x, S) I(x), (1 - \lambda) \phi'(S) \right\rangle. \end{aligned} \quad (8)$$

ただし、 $\langle \rangle$ は、二つのベクトルを並べて一つのベクトルにする操作 (concatenation) を表すことにする。よって、 $\mathbf{w}_{comb} = \langle \mathbf{w}, \mathbf{w}' \rangle$ である。また、 λ は単語極性反転モデルの影響を表すパラメータである。このモデルもまた一般的な識別モデルであり、SVM をはじめ様々なアルゴリズムを用いたパラメータの推定が可能である。また、素性関数 $\phi'(S)$ として、Bag-of-Words や依存構造木を利用することによって、これらの情報を取り込んだモデルとして学習が可能である。

文単位学習同様、このモデルにも柔軟な学習をする効果がある。また、単語感情極性辞書は必ずしもすべての単語を含んでいるわけではない。特にドメインに依存した表現などは含まれていないことが多い。単語感情極性辞書に載っている単語にのみ依存した単語極性反転モデルだけでは、辞書に載っている単語をあまり含まない事例をうまく分類できないことも考えられる。単語の極性だけからでは判断が難しい事例に対しては、その他の情報を用いて判定するように学習する。逆の場合も同様である。つまり、互いのモデルを補い合うようなモデルになっている。

4.4 考 察

依存構造木や n グラムなどの素性も否定や極性反転をある程度とらえることができるだろう。例えば、“美しい”はポジティブだが、“美しく+ない”はネガティブであるという違いは、2 グラム素性でもとらえられる。しかし、2 グラム素性は、これを一般化することができない。訓練データから学習し、“美しく+ない”がネガティブだとわかったとしても、その知識を“綺麗で+ない”に応用することはできないのである。一方、提案手法はこの場合、“ない”が極性反転を起こすことを学習するので、その学習結果の一般化が可能である。大量の訓練データが使用可能な場合は、 n グラム素性などでも、極性反転した表現の大半を被覆できるが、そうでない場合は特に提案手法がその性能を発揮すると期待される。

また、提案手法は、極性反転が起きるか否かをとらえるだけでなく、反転の強さを表す重み w を推定する。この重みは、特に文単位学習では、分類器の予測性能が最適化されるように推定されるので、より高性能な分類が期待できる。このような重みを人手で決定することは非常に困難であろう。

さらに、本稿で提案した全てのモデルはカーネル関数としての表現が可能である。例えば結合モデルは以下のようなカーネルを用いたモデルであると解釈できる：

$$K_{comb}(S_1, S_2) = \lambda \sum_{x_i \in S_1} \sum_{x_j \in S_2} K((x_i, S_1), (x_j, S_2)) + (1 - \lambda)K'(S_1, S_2). \quad (9)$$

ここで、 (x_i, S_1) は文中に出現する極性付き単語を表し、また K は文中に出現する極性付き単語同士のカーネル、 K' は評価文同士に定義されるカーネルである。これらのカーネルを高次の多項式カーネルとすることで、素性間の組み合わせを考慮した学習が可能である。

式中、 $\sum_{x_i \in S_1} \sum_{x_j \in S_2} K((x_i, S_1), (x_j, S_2))$ は、一種の畳み込みカーネル関数であると見なすことができる [Haussler 99]。畳み込みカーネル関数は、事例の部分構造におけるカーネル関数を足し合わせることで構成され

表 1 使用したコーパスの統計

	Customer Review	Movie Review
全事例数	1700 文	10662 文
適用可能事例数	1436 文	9492 文
極性付き単語	3276 単語	26493 単語
反転している単語	1076 単語	10674 単語

るカーネル関数である。提案手法では、文が事例に、極性付き単語が部分構造に対応している。

5. 評 価 実 験

本節では、提案手法の有効性を確認するために行った評価実験について報告する。

5.1 実験に用いたデータ

単語評価極性辞書（極性を持つ単語が収集されたもので、各単語がポジティブかネガティブかを示す情報が付与されている）としては General Inquirer [Stone 66] から抽出し、前処理を加えたものを用いた。これにはポジティブ極性の付与された単語 2084 語とネガティブ極性の付与された単語 2685 語が含まれている。ただし、語義によって極性が変化するような単語は今回の実験では含めなかった。ここでは、この辞書に含まれている単語を極性付き単語と呼んでいることに注意していただきたい。

評価文分類実験の評価データには Hu ら [Hu 04] による Customer Review^{*2} と Pang ら [Pang 05] による Movie Review^{*3} の 2 つのコーパスを用いた。これらは共に文単位に感情極性の付与された英文コーパスで、評価情報分析で用いられることの多いデータセットである。事例数などの統計を表 1 に示す。

提案手法では単語評価極性辞書を元に文中の感情極性を持つ単語を抽出し、分類に利用する。感情極性を持つ単語が一つも抽出されない文に対しては提案手法を適用できないため、実験に用いるデータセットから除外した。表 1 中の適用可能事例数は、手法の適用が可能で実際に実験に用いた事例数である。また、極性付き単語数は、コーパスから抽出された極性付き単語の延べ数、反転している単語は単語の極性と文全体の極性が異なり、極性が反転していると考えられる単語の延べ数である。

なお、実験の際にはこのデータを文単位で均等に 5 分割し、交差検定による評価を行った。また、評価尺度としては正解率を用いた。

*2 <http://www.cs.uic.edu/~liub/FBS/FBS.html>

*3 <http://www.cs.cornell.edu/people/pabo/movie-review-data/>

表 2 手法ごとの評価文分類の正解率の比較

手法	Customer Review	Movie Review
ベースライン	0.638	0.504
BoW	0.790	0.724
2gram	0.809	0.756
3gram	0.800	0.762
Simple-Voting	0.716	0.624
Negation-Voting	0.733	0.658
単語単位学習	0.783	0.699
文単位学習	0.806	0.718
結合モデル-BoW	0.827	0.748
結合モデル-2gram	0.840	0.755
結合モデル-3gram	0.837	0.758
結合モデル (最適 λ)	0.840	0.770

5.2 実験設定

本稿では各モデルのパラメータ推定アルゴリズムとして、オンライン最大マージン学習アルゴリズムを用いた [Crammer 06][McDonald 07]*4. このアルゴリズムはシンプルで実装も容易でありながら、予備実験において SVM と同程度かそれ以上の性能を示した。単語極性反転モデルの素性表現 $\phi(x, S)$ としては、単語 x 自身を含む周囲 n 単語と単語 x に付与された極性を用いた 2 値ベクトルを用いた。また、予備実験より $n = 3$ とした。

また、全てのモデルに対し 2 次の多項式カーネルを用いた。これは、Bag-of-Words のみを用いた評価文分類実験において最も高い正解率を得たカーネルである。素性ベクトルは L2 ノルムが 1 になるように正規化した。結合モデルでは、 $\sum_{x \in S} \phi(x, S) I(x)$ と $\phi'(S)$ をそれぞれ正規化した。結合モデルでは、2 つの異なる方法で作られたベクトルを結合しており、この際それぞれのベクトルのノルムが大きく異なると学習時のウェイトに大きな差が生まれてしまう。これを回避するため、各ベクトルを正規化している。

5.3 評価文分類実験

提案手法の有効性を確認するため、評価文分類による評価実験を行った。この実験では、以下の手法についてそれぞれ実験し比較した:

- **ベースライン**: すべての文をポジティブ極性を持つと判定。
- **BoW, 2gram, 3gram**: それぞれ Bag-of-Words, 2 グラム, 3 グラムを素性として利用したモデルによる分類。単語の極性を利用しない。
- **Simple-Voting**: 極性付き単語の出現数による、最も単純な多数決を用いた評価文分類。

● **Negation-Voting**: 多数決による手法だが、否定表現による極性反転を考慮しており、Hu らの手法 [Hu 04] に相当する。Simple-Voting 同様、文中の極性付き単語の出現数により多数決を行い文の極性を決定するが、その際、極性付き単語の周囲 3 単語以内に否定表現が出現する場合、単語の極性を反転して数える。実際に用いた否定表現は、not, no, yet, never, none, nobody, nowhere, nothing, neither であり、いくつかの先行研究で使用された表現を集めたものである [Polanyi 04, Kennedy 05, Hu 04]。なお、否定表現により極性を反転させる場合として周囲 3 単語以内としたのは、5.2 節で述べた提案手法の場合と合わせるためである。

- **単語単位学習**: 4.1 節で述べた、単語単位学習を行った単語極性反転モデルによる評価文分類。
- **文単位学習**: 4.2 節で述べた、文単位学習を行った単語極性反転モデルによる評価文分類。
- **結合モデル-BoW, 結合モデル-2gram, 結合モデル-3gram**: 4.3 節で述べた、文単位学習と既存の手法を結合したモデルによる評価文分類。それぞれ、BoW, 2gram, 3gram と結合した。また、 $\lambda = 0.5$ とした。
- **結合モデル(最適)**: これも 4.3 節で述べた結合モデルによる評価文分類。ただし、それぞれのデータセットに対して、最適の手法と結合し、最適の λ を用いた。最適なパラメータは、 $[0.0, 1.0]$ の範囲を有効数字 1 桁で変化させ、人手でチューニングした。チューニングで達成できる、結合モデルの上限と考えられる。

実験結果を表 2 に示す。Customer Review, Movie Review の両データで、提案手法である結合モデルが最も良い結果を得た。

Simple-Voting や Negation-Voting を、単語単位学習や文単位学習は大きく上回っており、単語極性反転モデルを用いることにより、単語極性の反転が捉えられていることがわかる。さらに学習法を工夫した文単位学習についても、単語単位学習を行った場合と比べ、正解率を向上させられることが確認できた。

また、特に Customer Review において、結合モデルは高い分類性能を発揮している。これより、単語極性反転モデルと、BoW などの既存手法との効果的な融合に成功していることがわかる。しかし、Movie Review については、既存手法と比較して良い結果は得られていない。この点については次節で議論する。ただし、結合モデル(最適)は両データセットにおいて最適な値を示しており、適切なチューニングにより、良い結果が得られることが期待できる。

5.4 訓練データサイズによる影響

訓練データサイズが大きい場合、 n グラムを素性とした既存の分類手法でも、それぞれの素性がどちらのクラスで出現しやすいかを学習できるだろう。しかし、訓練

*4 具体的には、[Crammer 06] 中の Figure 1 で紹介されている手法を用いている。

データサイズが十分でない場合、既存の分類手法ではそのような傾向を学習できず、そのような場合は我々の提案手法が非常に優位であると予想できる。

この予想を調査するため、訓練データのサイズを変化させて実験を行った。ここでは、3gram、文単位学習、結合モデル 3gram の三種類を試した。Customer Review と Movie Review の両方に対して実験を行った。




図 1 訓練データ量に対する分類正解率 (Customer Review)

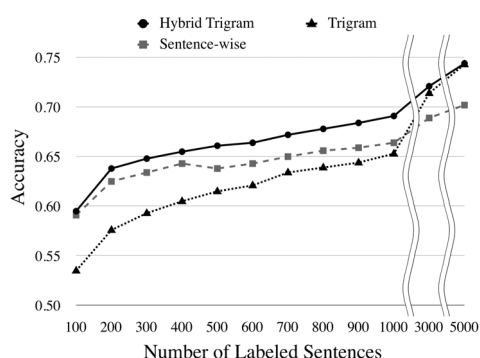


図 2 訓練データ量に対する分類正解率 (Movie Review)

図 1, 図 2 に、それぞれ Customer Review, Movie Review に対する結果を示す。どちらにおいても、訓練データが小さい場合には、文単位学習が 3gram を上回っている。また、訓練データが大きくなるにつれ、文単位学習の優位性が小さくなることがわかる。また、結合モデル 3gram は常に良い値を示している。これにより、提案手法は、特に訓練データが小さい場合に、既存手法との差が明確になることがわかった。また、結合モデルは二つのモデルを効果的に融合していることもわかった。

さて、表 1 を見ると、Movie Review は Customer Review と比較してデータサイズが大きい。前節で、Movie Review に対しては、結合モデルと既存の教師有り手法がほぼ同等の結果を出していることを確認した。本節の実験結果を見ると、これは、Movie Review のサイズが十分に大きいため、既存の教師有り手法でも十分に対応できるからであると考えられる。

6. 結論と今後の課題

本稿では評価文中の単語の極性の反転を捉える、単語極性反転モデルを提案し、その評価文分類への応用法について述べた。さらに、このモデルに対し単語単位学習と文単位学習という二種類の学習方法を提案し、さらに既存のモデルとの結合による拡張を行った。英文コーパスに対し評価文分類実験を行い、提案手法の有効性を実験的に示した。

今後の課題として、単語極性反転モデルに適した素性の発見が挙げられる。今回実験で用いた素性は極めて単純な素性であり、反転を捉えるために十分であるとは言えない。例えば単語の係り先や接続詞といった情報は有用と思われる。また、要素の位置によって重要性が異なるという先行研究も存在する [Taboada 04]。

文の極性に影響を及ぼさない単語についても考慮する必要があるだろう。提案手法では間接的にこれに対処したが、より効果的に単語の極性を他のタスクに応用していくためには、避けられない問題であると考えられる。

本稿では、すべての入力文が極性を持つようなデータを対象とした。本手法において、極性を持たない文を含むデータを扱うためには、出力 $score(S)$ の絶対値がある閾値より小さなものは極性を持たないと判定するなどのヒューリスティックスが必要である。このようなヒューリスティックスに依らず無極性文を判定できるような拡張モデルは、応用上非常に重要であろう。

また、本論文では単語の極性を利用した評価文分類手法を提案したが、今後はこれをさらに文書レベルまで拡張したいと考えている。

◇ 参 考 文 献 ◇

- [Crammer 06] Koby Crammer, Ofer Dekel, Joseph Keshet, Shai Shalev-Shwartz, and Yoram Singer. Online Passive-Aggressive Algorithms. In *Journal of Machine Learning Research*, Vol.7, Mar, pp.551–585, 2006.
- [Gamon 04] Michael Gamon. Sentiment classification on customer feedback data: noisy data, large feature vectors, and the role of linguistic analysis. In *Proceedings of the 20th International Conference on Computational Linguistics (COLING-2004)*, pp.841–847, 2004.
- [Hatzivassiloglou 97] Vasileios Hatzivassiloglou and Kathleen R. McKeown. Predicting the Semantic Orientation of Adjectives. In *Proceedings of the 35th Annual Meeting of the Association for Computational Linguistics and the 8th Conference of the European Chapter of the Association for Computational Linguistics*, pp.174–181, 1997.
- [Haussler 99] David Haussler. Convolution Kernels on Discrete Structures, UC Santa Cruz Technical Report UCS-CRL-99-10, 1999.
- [Hu 04] Mingqing Hu and Bing Liu. Mining and Summarizing Customer Reviews. In *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD-2004)*, pp.168–177, Seattle, USA, August 2004.
- [Kamps 04] Jaap Kamps, Maarten Marx, Robert J. Mokken and Maarten de Rijke. Using WordNet to measure semantic orientation of adjectives. In *Proceedings of the 4th International Conference on Language Resources and Evaluation (LREC 2004)*, Vol.IV, pp.1115–1118, 2004.
- [Kennedy 05] Alistair Kennedy and Diana Inkpen. Sentiment Classi-

- fication of Movie and Product Reviews Using Contextual Valence Shifters. In *Proceedings of Workshop on the Analysis of Formal and Informal Information Exchange during Negotiations (FINEXIN)*, 2005.
- [Mao 06] Yu Mao and Guy Lebanon. Isotonic Conditional Random Fields and Local Sentiment Flow. In *Proceedings of the Neural Information Processing Systems (NIPS-2006)*, pp.961–968, 2007.
- [Matsumoto 05] Shotaro Matsumoto, Hiroya Takamura, and Manabu Okumura. Sentiment Classification using Word Sub-Sequences and Dependency Sub-Trees. In *Proceedings of the 9th Pacific-Asia International Conference on Knowledge Discovery and Data Mining (PAKDD-2005)*, pp.301–310, 2005.
- [McDonald 07] Ryan McDonald, Kerry Hannan, Tyler Neylon, Mike Wells, and Jeff Reynar. Structured Models for Fine-to-Coarse Sentiment Analysis. In *Proceedings of the 45th Annual Meeting of the Association for Computational Linguistics (ACL-2007)*, pp.432–439, 2007.
- [Mullen 04] Tony Mullen and Nigel Collier. Sentiment analysis using support vector machines with diverse information sources. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP-2004)*, pp.412–418, 2004.
- [Pang 02] Bo Pang, Lillian Lee, and Shivakumar Vaithyanathan. Thumbs up? Sentiment Classification using Machine Learning Techniques. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP-2002)*, pp.76–86, 2002.
- [Pang 04] Bo Pang and Lillian Lee. A Sentimental Education: Sentiment Analysis Using Subjectivity Summarization Based on Minimum Cuts. In *Proceedings of the 42th Annual Meeting of the Association for Computational Linguistics (ACL-2004)*, pp.271–278, 2004.
- [Pang 05] Bo Pang and Lillian Lee. Seeing stars: Exploiting class relationships for sentiment categorization with respect to rating scales. In *Proceedings of the 43rd Annual Meeting of the Association for Computational Linguistics (ACL-2005)*, pp.115–124, 2005.
- [Polanyi 04] Livia Polanyi and Annie Zaenen. Contextual Valence Shifters. In *Proceedings of AAAI Spring Symposium on Exploring Attitude and Affect in Text: Theories and Applications*, 2004.
- [Stone 66] Philip J. Stone, Dexter C. Dunphy, Marshall S. Smith, and Daniel M. Ogilvie. The General Inquirer: A Computer Approach to Content Analysis. The MIT Press, 1966.
- [Taboada 04] Maite Taboada and Jack Grieve. Analyzing Appraisal Automatically. In *AAAI Spring Symposium on Exploring Attitude and Affect in Text: Theories and Applications(AAAI-EAAT2004)*, pp.158–161, 2004.
- [Turney 03] Peter D. Turney and Michael L. Littman. Measuring praise and criticism: Inference of semantic orientation from association. *ACM Transactions on Information Systems*, Vol.21, No.4, pp.315–346, 2003.
- [乾 06] 乾 孝司, 奥村 学, テキストを対象とした評価情報の分析に関する研究動向. 自然言語処理, Vol 13, No.3 pp.201–241, 2006.
- [工藤 04] 工藤 拓, 松本 裕治, 半構造化テキストの分類のためのブースティングアルゴリズム. 情報処理学会論文誌, Vol.45 No.9 pp.2146–2156, 2004.
- [小林 01] 小林のぞみ, 乾孝司, 乾健太郎語釈文を利用した「p/n 辞書」の作成. 人工知能学会 言語・音声理解と対話研究会 SLUD-33, pp.45–50, 2001.
- [貞光 07] 貞光 九月, 山本 幹雄, 文を単位とする文書構造を利用した評価文書分類. 言語処理学会第 13 回年次大会予稿集, pp.230–233, 2007.
- [高村 06] 高村 大也, 乾 孝司, 奥村 学, スピンモデルによる単語の感情極性抽出. 情報処理学会論文誌, Vol.47 No.2 pp.627–637, 2006.

〔担当委員：熊本 忠彦〕

2009 年 4 月 28 日 受理

著 者 紹 介



池田 大介

2006 年東京工業大学工学部情報工学科卒業. 2008 年同大大学院総合理工学研究科知能システム科学専攻修了. 修士(工学). 2008 年よりグーグルジャパン勤務. 自然言語処理に興味を持つ.



高村 大也(正会員)

1974 年生. 1997 年東京大学工学部計数工学科卒業. 2000 年同大大学院工学系研究科計数工学専攻修了(1999 年はオーストリアウィーン工科大学にて研究). 2003 年奈良先端科学技術大学院大学情報科学研究科博士課程修了. 博士(工学). 2003 年より東京工業大学精密工学研究所助手(現在助教). 自然言語処理, 特に学習理論等の応用に興味を持つ. 情報処理学会, ACL 各会員.



奥村 学(正会員)

1962 年生. 1989 年東京工業大学大学院情報理工学研究科計算工学専攻博士後期課程修了. 1989 年より東京工業大学大学院情報理工学研究科助手. 1992 年より 2000 年北陸先端科学技術大学院大学助教授. 1997 年より 1998 年トロント大学客員助教授. 2000 年より東京工業大学精密工学研究所助教授. 自然言語処理, 自動テキスト要約, コンピュータによる語学学習支援, テキストデータマイニングに関する研究に従事. 工学博士.