

原著論文

# 単語の持つ感情推定法の提案と単語感情辞書の構築

武内 達哉, 萩原 将文

慶應義塾大学大学院

## A Proposal of Emotion Estimation Method for Words and Construction of Word-emotion Dictionary

Tatsuya TAKEUCHI and Masafumi HAGIWARA

Faculty of Science and Technology, Keio University, 3-14-1 Hiyoshi, Kohoku-ku, Yokohama, Kanagawa 223-8522 Japan

**Abstract :** In this paper, we propose an emotion estimation method for words and its application to construct a word-emotion dictionary. Since the estimation of more delicate emotions in various natural language processing tasks is a crucial issue, we aim to estimate various emotions to a word. In order to realize it, we employ the distributional hypothesis and assume that an emotional word in a sentence influences the surrounding words. First, we collect more than 2,000 words expressing emotions from an emotion expression dictionary. By using these emotional words and a neural model based on Continuous Bag-of- Words (CBOW), we propose an automatic system to estimate the emotions of many ordinary words. As a result, emotion vectors for 20,000 words could be obtained. We carried out experiments to examine the accuracy of the vectors. It is confirmed that the generated emotion vectors reflect the emotion image for words that humans have.

**Keywords :** Natural language processing, Emotion estimation, Word-emotion dictionary

### 1. は じ め に

自然言語処理において、入力したテキストを解析し、感情を推定する研究は非常に盛んである。例えば、本間ら [1] はニュース記事とそれに関連する SNS の投稿を感情推定し、アクセス解析に利用している。また、徳久ら [2] は対話システムにおいて対話相手の発話内容から感情を推定している。このように、自然言語処理における感情推定は様々な応用が可能であり、非常に実用的なタスクである。

感情推定を行うためのアプローチの一つとして、単語に対し感情を推定するという研究がある。単語をポジティブ(望ましい)とネガティブ(望ましくない)の間で分類する、いわゆる単語の極性分類の既存研究としては、文献 [3-8] が挙げられる。また、池田ら [9] はこれらの研究により構築された単語極性辞書を用い、実際に文の極性評価を行なっている。

一方で、感情をポジティブとネガティブの2種類のみとしてしまうのは、分類の種類としては十分ではない。人間の持つ感情について、例えば Ekman [10] は5種類に分類し、Plutchik [11] は8種類の分類を提唱している。これらに基づき、より細かく感情を分類することで、自然言語処理でより多くの感情を扱うことが可能であると考えられる。

また、単語が持つ感情は必ずしも一つではないという問題も存在する。例えば、「車」という単語を聞いて、ドライブなどから楽しい感情を連想する人もいれば、自動車事故などから恐怖の感情を連想する人もいる。すなわち、単語をどれか一つの感情に分類するよりも、それぞれの感情に対してど

れくらいの程度を持っているのかを定義する方が自然であると考えられる。

単語に複数の感情の情報を付与する研究としては、齋藤らの研究 [12] がある。文献 [12] の研究では感情表現辞典 [13] から感情を表す単語を抽出し、他の単語に対して web 検索の結果や新聞のコーパスデータを利用して10感情の値を付与している。しかし、文献 [12] の研究では、大規模な辞書構築について言及しておらず、自動的に多くの語彙について感情を推定できないという問題が残っている。

そこで本論文では、多数の単語について自動的に複数の感情を推定する手法の提案を行い、その手法に基づき単語と感情の情報を結びつけた辞書の構築を行う。感情の推定では、Mikolov ら [14] により提唱された、Continuous Bag-of-Words モデル (CBOW) をもとにしたニューラルモデルを用いる。文献 [14] の研究では、同じ文脈で使用されている単語は同じ意味を持つ、すなわち単語の役割は周囲の単語から推定可能であるという分布仮説に基づいている。この仮説に基づき、大量のテキスト内で周りの単語から中心の単語を推定する学習を行う。そして、その学習により得られたニューラルモデルの重みを、単語の特徴を表す分散表現としている。本論文ではこの研究を応用し、感情を表す単語(以下、感性語と呼ぶ)の周りの単語から感性語の感情を推定する学習を行う。そして、学習により得られるニューラルモデルの重みを、各単語の感情の値とする(以下、感情ベクトルと呼ぶ)。この手法により、少数の感性語をもとに、感性語ではない多数の単語(以下、一般単語と呼ぶ)に対する感情の推定が可能となっている。

評価実験では、ランダムに選出した単語に対し被験者が複数の感情の推定を行い、その結果と提案手法によって生成された感情ベクトルの比較を行う。

以下本論文では、第2章で提案する感情推定手法について述べる。第3章で評価実験を説明する。第4章の結論をまとめとする。

## 2. 単語の持つ感情推定法についての概要

提案手法では、感性語の感情を基に、周囲の一般単語の感情の推定を行う。これは、感性語が周囲の単語に感情的な影響を与えているという仮定に基づく手法である。例として、「海で泳ぐのは楽しい」という文を考える。この場合、「海」という単語は「楽しい」という単語により、「楽」の感情のイメージが付与されていると考えられる。一方で、「海のように深い悲しみ」という文を考える。この場合、「悲しみ」という単語により、「哀」の感情のイメージが付与されていると考えられる。このように、多くの一般単語は感性語と共にどのような使われ方をするかによって感情のイメージが定まる。これを利用して、多くの一般単語に対し、多様な感情のイメージを推定する。

推定の具体的な手段として、ニューラルネットワークによる学習を利用する。感性語の感情が周囲の単語に影響を与えるということは、逆に捉えれば、周囲の一般単語の感情から感性語の感情を推定可能であるとも考えられる。この推定モデルを学習し、感性語の感情を推定する精度を向上させる。その推定精度が高ければ高いほど、周囲の一般単語の持つ感情の値は、感性語から受ける感情の影響を強く反映していると言える。

本章では、提案手法の流れを順に説明する。

### 2.1 感情の分類の定義

感情の分類はいくつかの手法が提案されている。その中でも中村 [13] は言語表現の観点から、感情を「喜, 怒, 哀, 怖, 恥, 好, 厭, 昂, 安, 驚」の10感情に分類している。本研究では言語、その中でも日本語を扱うため、この分類手法を採用する。

### 2.2 感性語の収集

感情表現辞典 [13] では、前節で述べた10感情分類を基に、各感情を表す単語や熟語2,278語が収録されている。提案手法ではこれらの単語を、該当する感情は1の値を、該当しない感情は0の値を持つものとし、感性語としてリスト化する。例えば、「厚意」という感性語は「喜」と「好」という感情を有すると定義されている。このとき、「厚意」の感情ベクトルは

$$\begin{aligned} & (\text{喜, 怒, 哀, 怖, 恥, 好, 厭, 昂, 安, 驚}) \\ & = (1, 0, 0, 0, 1, 0, 0, 0, 0) \end{aligned}$$

となる。このベクトルを学習の際に利用する。

また、各感性語は一度分かち書きを行い、2語以上に分解されるものはリストから除外する。分かち書きとは、文など

表1 感性語の例

感情の種類	感性語の例
喜	喜ぶ, 感謝, 祝賀, かたじけない, …
怒	反感, 睨む, 怒鳴る, 逆鱗, …
哀	哀悼, 嘆く, 涙ぐむ, 憐れみ, …
怖	恐ろしい, 畏怖, 怯える, たじろぐ, …
恥	赤面, 羞恥, 屈辱, こそばゆい, …
好	友情, 恋愛, 慕う, 憧れる, …
厭	不快, 苦々しい, 厭蹙, 疎む, …
昂	感服, 嘆美, 奮起, 激情, …
安	安心, 寛ぐ, 落ち着く, 呑気, …
驚	驚愕, ショック, 意外, 咄然, …

を単語単位や文節単位で空白を入れ区切ることである。提案手法では、分かち書きは単語単位で区切ることを目指す。例えば、「臍を曲げる」という感性語は分かち書きによって「臍」「を」「曲げる」というように分解されるため、除外の対象となる。これは、提案手法が単語単位で学習を行う上で、分解された単語のうちどの単語が感情を有しているのか定義が困難であるためである。分かち書きには形態素解析エンジンである MeCab [15] を用いる。

表1に感性語の例を示す。

### 2.3 学習データの作成

提案手法で学習に用いるデータセットは、データ量が多い、口語表現が少ない、幅広い語彙を有するという条件より、日本語版 Wikipedia [16] から収集した。

日本語版 Wikipedia から収集したデータは、提案手法で扱うために加工する必要がある。まず、マークアップ言語の情報や脚注などを取り除き、完全なテキストとする。次に、記号や英数字、句読点や改行を取り除く。そして最後に分かち書きを行う。このとき、分かち書きによって分かれた各単語は、単語の原型に変形する。文生成のようなタスクとは異なり、単語の活用形による差異は考慮しないためである。また、このとき、名詞、動詞、形容詞、形容動詞以外の単語はデータから削除した。これは、感情の情報をあまり含まないと考えられる単語群を除くためである。これにより、学習時に感情を持たない単語を計算から除外することが可能となる。これらの処理により、データセットは単語の羅列となる。

この分かち書きした単語群と、前節で作成した感性語の単語群を合わせて、語彙のリストを作成する。そして、システムが識別できる語彙数に上限（本論文では20,000語とした）を定め、それに含まれない単語はデータセット自体から削除する。これは、学習にほとんど登場しない単語を除くことで学習自体の精度を上げるためである。

通常、語彙に含めるかどうかの判断としては、全ての単語を登場回数でソートするのが一般的である。しかし、提案手法では、教師データとして感情の値を持つのが感性語のみであり、感性語の周辺に発生する単語しか学習できない。すな

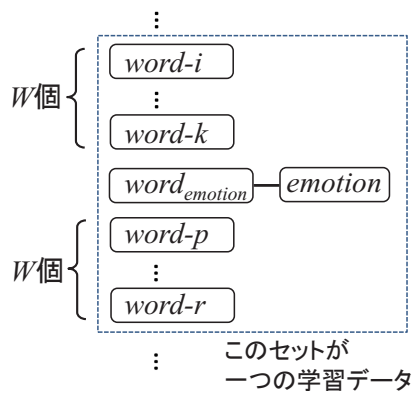


図1 学習データの作成

わち、学習データ内において感性語が多いほど感情の値を学習できる単語も多くなる。そのため、二つの単語群を合わせてから登場回数でソートするのではなく、Wikipediaの単語群をソートし語彙を絞った後、感性語の語彙と合わせる。この処理により、登場回数が少ないという理由で感性語が語彙から除外されることを防ぐことが可能となる。

次に、単語の羅列であるデータセットを入力データとして加工する。図1にその様子を示す。まず、感性語の前後でいくつの単語を学習に利用するかを決定する。この値をウィンドウサイズとし、 $W$ と表記する。次に、データセットの単語を始めから順に見ていき、感性語リストに含まれている単語を探す。感性語があった場合、中心の感性語である  $word_{emotion}$  とその感情である  $emotion$ 、そして前後の  $W$  個の単語群をセットにする。このとき、感性語と周囲の単語が入力データであり、感情が出力のデータとなる。これを一つの学習データとする。「厚意」のように感性語が2つ以上の感情を有している場合、同じ入力に対して、出力がそれぞれの感情である学習データを作成する。この処理をデータセットの最後の単語に到達するまで繰り返す。

## 2.4 ニューラルモデルによる学習

図2に学習で利用するニューラルモデルを示す。 $word(n)$  が感性語であり、 $n$  は感性語の位置、 $W$  はウィンドウサイズである。

入力層は語彙数が次元数であるベクトルであり、これは語彙のリストのインデックスに対応している。ある単語を入力としたとき、その単語を表す部分の値が1となり、それ以外の値は0となる。すなわち、このモデルに学習データを入力したとき、学習データ内に登場する単語のインデックスは1、登場しない単語のインデックスは0が入力となる。例として、学習データを入力したとき、 $W$  が3の場合は、入力単語は感性語を含め7個となる。このとき、入力層のベクトルは、7カ所が1であり、他が0の値を持つベクトルとなる。

入力層と中間層の間の重み  $w_1$  は、語彙数を  $v$ 、感情の分類数を  $d_s$  とすると、 $(v \times d_s)$  の行列で表せる。これは、すべての単語が各感情に対し値を保持しているとみなすことができる。

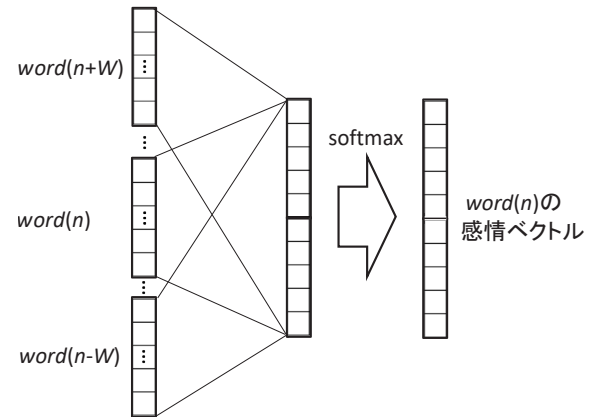


図2 学習で利用するニューラルモデルの構成

学習後、この重みの値を感情ベクトルの素として取得する。

中間層は、ウィンドウサイズ分だけ入力層に入力し、その値と重み  $w_1$  を掛け合わせた和である。この値は、入力した単語それぞれが持つ感情の値の和に等しい。

中間層の値は、 $softmax$  関数に代入され出力される。すなわち、出力層は  $word(n-W)$  から  $word(n+W)$  までの単語を入力した際に推定される感情の確率分布を表す。この出力値と学習データに含まれる出力の教師データである  $emotion$  について、交差エントロピーを最小化するように学習を行う。

## 2.5 感情ベクトルの取得

学習を行ったモデルに対し、入力層と中間層の間の重みの値を取得する。そして、その重みの値を  $softmax$  関数に代入する。これにより得られる値を、最終的な感情ベクトルとする。この  $softmax$  関数はベクトルの値の正規化が目的である。学習時に重みの値に対しては明示的な制約を与えていないため、重みの値の値域は単語ごとに異なり、基準値も存在していない。そのため、本論文では各感情を表す値の値域を0から1とし、それらの和が1となるように正規化する。これにより、値の比率を見ることで、単語の有する感情の比率を見ることが可能となる。

## 3. 評価実験

### 3.1 実験環境

感情表現辞典に掲載されている単語と熟語は前述のように2,278語である。このうち、分かち書きによって2語以上に分かれるものを除いた結果、1,245語を感性語として採用した。

学習に利用した日本語版 Wikipedia のデータセットは約3.7GBほどのサイズであった。システムが認識可能な語彙数は出現頻度が高い順から20,000語とした。これを感性語のリストと足し合わせた結果、語彙数は21,032語であった。データセットをテキスト化し、語彙に含まれない単語を全て削除した結果、203,448,080語となった。 $W$  を3とし、この単語群から学習データを作成した結果、1,496,886組の学習データが作成された。

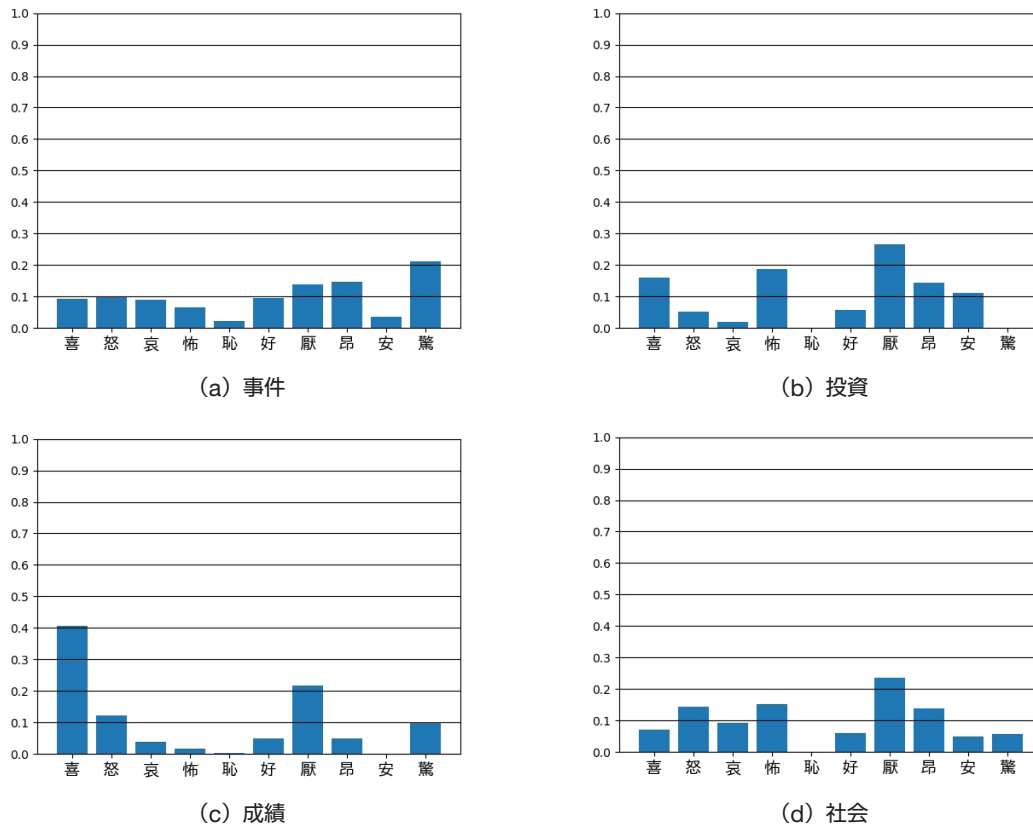


図3 生成した一般単語の感情ベクトル




図4 生成した感性語の感情ベクトル

また、過学習を防ぐため、学習に利用したデータセットとは別に、日本語版 Wikipedia から 1.9GB 分の検証データを用意した。

### 3.2 感情ベクトルの生成例

図3に実際に生成した一般単語の感情ベクトルの例を示す。図の横軸は感情の分類を、縦軸はそれぞれの感情の値を表している。次に、図4に感性語の感情ベクトルの例を示す。図3と同様に、横軸は感情の分類を、縦軸はそれぞれの感情の値を表している。

まず、図3を見ると、一般単語ではベクトルの値が多くの感情に分散している。一方で、図4を見ると、感性語はベク

トルの値が一つの感情に固まっている傾向が見られる。

感性語の感情ベクトルを見ると、「めでたい」という単語は「喜」の感情と一致し、「敬愛」という単語は「好」の感情と一致していることが示されている。これらの感情は、学習時に教師データとして用いた、感情表現辞典に記された感情とおおよそ一致している。このことから、感性語は自身の感情を正しく学習していることが示唆される。

また、一般単語は感性語とは異なり、複数の感情に対してベクトルの値を持っていることが示されている。これは、文中の様々な使用法で感性語から影響を受けたため、複数の感情の情報を持っているという、一般的な知見に沿った結果となっている。



表2 評価実験のため選出した単語群

出現頻度	一般単語	感性語
A 群	影, 成績, 遊ぶ, 社会, 文字, 衝突, …	不安, 失恋, 苦痛, 安心, 敬愛, 迷惑, …
B 群	バナナ, 幻覚, 象, 海, 学院, 体育, …	踊る, 辟易, 渴望, 感嘆, 憂慮, 憤怒, …
C 群	投資, 核兵器, 墓所, 血圧, 公正, バネ, …	和やか, 憔悴, 震撼, 謝意, 惑い, 大慶, …

### 3.3 評価実験

提案手法で生成した単語の感情ベクトルの適切さについて評価実験を行った。実験手順は以下の通りである。

まず、実験環境の語彙から以下のように単語を選出した。単語の選出は、学習データ内での単語の出現頻度をもとに決定した。具体的には、一般単語と感性語の語彙をそれぞれ出現頻度でソートし5等分する。出現頻度が多い領域からA, B, C, D, Eとすると、A, B, Cの領域から10単語ずつ単語をランダムに選出した。これにより、一般単語と感性語で30単語ずつ、計60単語を選出した。

表2に実際に選出した単語の例を示す。

次に、被験者にそれらの単語について思い浮かべる感情の比率を回答してもらった。例えば、ある単語について「喜」と「哀」と「驚」が同じくらいあり、他はイメージしないという場合なら、

(喜, 怒, 哀, 怖, 恥, 好, 厭, 昂, 安, 驚)

= (1,0,1,0,0,0,0,0,1)

のように回答してもらう。また、「怒」が少しあり、「厭」がとても大きいと思う場合なら、

(喜, 怒, 哀, 怖, 恥, 好, 厭, 昂, 安, 驚)

= (0,1,0,0,0,0,3,0,0,0)

のように回答してもらう。1つ以上ならば感情はいくつでも選択して良いものとした。また、比率の値も自由である。データ処理の段階において、ベクトルの各要素の和が1になるように正規化を行なった。被験者は20代の男性13名、女性4名である。

評価によって得られた各単語の感情の数値は、比率の値が自由であったことから、正規化する必要があった。本実験では各個人の各単語についてまずsoftmax関数に代入し、値の合計を1とした後、それぞれの単語について平均値を求めた。これにより、生成した感情ベクトルと値の比較が可能となる。

以上の手順により得られた平均値（以下、評価用ベクトルと呼ぶ）と生成した感情ベクトルについて、次の項目で評価実験を行った。

- (1) 感情ベクトルで1番高い値の感情が、評価用ベクトルの1番高い値の感情と一致しているか (TOP1)
- (2) 感情ベクトルの1番高い値の感情が、評価用ベクトルの上から3番目までの値が高い感情に含まれているか (TOP3)
- (3) 感情ベクトルと評価用ベクトルのコサイン類似度がどの程度か (cos類似度)
- (4) 感情ベクトルと評価用ベクトルの各要素の分散がどの程度か (分散)

表3 評価実験 (1)~(3) の結果

評価項目	一般単語	感性語
(1) TOP1	26.7%	56.7%
(2) TOP3	53.3%	86.7%
(3) cos類似度	0.695	0.664

表4 評価実験 (4) の結果

評価項目	一般単語	感性語
感情ベクトル	0.015	0.085
評価用ベクトル	0.005	0.012

### 3.4 実験結果

表3に評価実験 (1)~(3) の結果を示す。また、表4に評価実験 (4) の結果を示す。実験結果は一般単語と感性語で分けて表記した。

感情の一致の精度を見ると、TOP1, TOP3共に、一般単語に比べ感性語の方が高い結果となった。

一方で、生成した感情ベクトルと評価用ベクトルのコサイン類似度を算出すると、感性語の平均が0.664なのに対し、一般単語は0.695となった。この評価項目においては、感情ベクトルと評価ベクトルの間に明確な差が生じているとは断言できない結果となった。

感情ベクトルの分散の評価において、感性語が0.085であるのに対し、一般単語は0.015であった。

### 3.5 考察

提案手法では、Continuous Bag-of-Wordsモデルを参考にしたニューラルモデルで感情ベクトルの学習を行っている。多義性を有する単語の場合では、学習データ内においてそれぞれの多義性に応じた文が含まれている。この多義性の偏りに基づいて学習が行われ、感情ベクトルの各要素の値に反映されていると考えられる。

一方、特定の感情が強すぎる場合や、多義性の中に感情推定が難しい使い方が含まれている場合には、感情推定がうまくいかない傾向にあると推測される。

感情の一致について、感性語の方がより精度が高いのは、感性語の方が感情をイメージしやすいからであると考えられる。図4で生成した感情ベクトルに見られたように、感性語の感情ベクトルは感性語の感情を保持する傾向にあるのがわかる。一方、人間が感性語を見たときも、感性語が感情を表す言葉である以上、その語が持つ感情をイメージしやすい。このことから、感性語は感情の一致という評価基準において一般単語に優れていると考えられる。

分散の値について、一般単語の感情ベクトルが0.015であり、感性語の感情ベクトルは0.085となった。仮に、全ての値が0.1のベクトルならば分散は0となり、一つの値が1で他が全て0のベクトルならば分散は0.09となる。この結果を見ると、一般単語の感情ベクトルは複数の感情に値が散らばり、感性語の感情ベクトルはどれか1つの感情に大きな値を持つ傾向があると考えられる。実際に図3の感情ベクトルを見ると、その傾向が見られる。特に一般単語では、感情ベク

トルと評価ベクトルで値の分布が近いと考えられるため、生成した感情ベクトルは人間の持つ実際の感情に近いと考えられる。一方、評価用ベクトルでは、感性語においても分散の値が小さい。実際の評価ベクトルを見ると、感性語においても被験者が複数の感情を思い浮かべる傾向が見受けられた。学習に用いた感性語のデータセットはほとんどが1つあるいは2つの感情のみを表す単語としていたが、さらに人間のイメージに近いように初期値を設定することで、学習する感情ベクトルも人間の持つイメージに近くなると考えられる。

#### 4. 結 論

本論文では、単語の持つ感情推定法の提案と、それに基づく単語感情辞書の構築を行った。CBOWを基にしたニューラルモデルを使用し、感情の値がはっきりしている感性語を基準とすることで、一般単語の感情の値を推定した。この手法の特長は、指定した感情数に対応した感性語のデータセットを用いれば、単純な平文コーパスのみで感情推定を行うことが可能であるという点である。この手法に基づき、大規模な単語感情辞書の構築を行った。

生成したベクトルについて、複数の感情を持つ一般単語に関しては、それらの感情ベクトル値が多様な傾向がある。一方、感性語は自身が持つ感情の情報を反映していることが確認できた。また、評価実験を行い、人間の持つ実際の感情に近い感情ベクトルであることが示された。

また、課題の一つとして、辞書の規模の拡大がある。本論文によって生成した感情ベクトルを他のタスクに利用する際、本論文での実験環境として設定した語彙数では、タスクに必要な語彙数に達しない可能性も存在する。この解決策として、学習に利用するデータを増やすことが考えられる。学習データに含まれる単語が多ければ、感情ベクトルを生成できる語彙数も増大する。また、学習に使用した語彙のうち、学習頻度が低いものは精度の信頼性が低い。そのため、他の言語資源を用いて下位単語の学習を底上げする手法も有用である。

#### 参 考 文 献

- [1] 本間幸徳, 萩原将文: Twitter を用いたニュース記事における読み手の感情推定手法の提案とアクセス解析への応用, 日本感性工学会論文誌, 12(1), pp.167-174, 2013.
- [2] 徳久良子, 乾健太郎, 松本裕治: Web から獲得した感情生起要因コーパスに基づく感情推定, 情報処理学会論文誌, 50(4), pp.1365-1374, 2009.
- [3] Hatzivassiloglou, V., and Mckeown, K. R.: Predicting the semantic orientation of adjectives, Proceedings of the 35th Annual Meeting of the Association for Computational Linguistics and Eighth Conference of the European Chapter of the Association for Computational Linguistics, Association for Computational Linguistics, pp.174-181, 1997.
- [4] 小林のぞみ, 乾孝司, 乾健太郎: 語釈文を利用した「p/n 辞書」の作成, 人工知能学会言語・音声理解と対話研究会, SLUD-33, pp.45-50, 2001.
- [5] Turney, P. D., and Littman, M. L.: Measuring praise and criticism: Inference of semantic orientation from association, ACM Transactions on Information Systems (TOIS), 21(4), pp.315-346, 2003.
- [6] Kamps, J., Marx, M., Mokken, R. J., and de Rijke, M.: Using WordNet to measure semantic orientations of adjectives, Proceedings of LREC-04, 4th International Conference on Language Resources and Evaluation, pp.1115-1118, 2004.
- [7] Hu, M., and Liu, B.: Mining and summarizing customer reviews, Proceedings of the Tenth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp.168-177, 2004.
- [8] 高村大也, 乾孝司, 奥村学: スピンモデルによる単語の感情極性抽出, 情報処理学会論文誌, 47(2), pp.627-637, 2006.
- [9] 池田大介, 高村大也, 奥村学: 単語極性反転モデルによる評価文分類, 人工知能学会論文誌, 25(1), pp.50-57, 2010.
- [10] Ekman, P.: An argument for basic emotions, Cognition and Emotion, 6(3-4), pp.169-200, 1992.
- [11] Plutchik, R.: The emotion, Random House, New York, 1962.
- [12] 齋藤崇紘, 光部勇佑, 中谷和波, 韓東力: 名詞の感情属性の抽出とそれに基づく名詞間類似度の計算, 言語処理学会第14回年次大会, pp.368-371, 2008.
- [13] 中村明: 感情表現辞典, 東京堂出版, pp.5-20, 1993.
- [14] Mikolov, T., Chen, K., Corrado, G., and Dean, J.: Efficient estimation of word representations in vector space, arXiv preprint arXiv:1301.3781, 2013.
- [15] Kudo, T., Yamamoto, K., and Matsumoto, Y.: Applying conditional random fields to Japanese Morphological analysis, Proceedings of the EMNLP-2004, pp.230-237, 2004.
- [16] Wikipedia 日本語版メインページ: <https://ja.wikipedia.org/wiki/> (2018.12.08 閲覧).



武内 達哉 (非会員)

2017 年慶應義塾大学理工学部卒業。2019 年同大学大学院開放環境科学専攻修士課程修了。在学中、自然言語処理における分散表現の研究及び感性工学の研究に従事。現在、株式会社野村総合研究所勤務。



萩原 将文 (正会員)

1982 年慶大・工・電気卒。1987 年同大学院博士課程修了。工博。同年同大助手。現在、同大教授。1991-92 年度スタンフォード大学訪問研究員。視覚・言語・感情情報処理とその融合の研究に従事。1990 年 IEEE Consumer Electronics Society 論文賞, 1996 年日本ファジィ学会著述賞, 2003 年日本感性工学会技術賞, 2004 年, 2014 年同学会論文賞, 2013 年日本神経回路学会最優秀研究賞, 2018 年日本知能情報ファジィ学会論文賞受賞。